## LB3

```
In []: import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import apriori
```

## PART 1 DATA

Загрузка и первичная подготовка датасета.

```
all data = pd.read csv("data/dataset group.csv", header=None)
In [104...
           all data.head()
                     0 1
                                     2
Out [104...
          0 2000-01-01 1
                                 yogurt
          1 2000-01-01
                                  pork
            2000-01-01
                       1
                          sandwich bags
             2000-01-01 1
                             lunch meat
             2000-01-01 1
                            all-purpose
           unique id = list(set(all data[1]))
In [105...
           len(unique id)
Out[105... 1139
In [106...
           items = list(set(all_data[2]))
           len(items)
Out[106... 38
           dataset = [[elem for elem in all_data[all_data[1] == id][2]
In [107...
                         if elem in items] for id in unique_id]
```

## PART 2 PREPROCESSING

2

3

False

True

False

False

True False

False False

Необходимо представить данные в виде матрицы.

```
te = TransactionEncoder()
In [108...
            te_ary = te.fit_transform(dataset)
            df = pd.DataFrame(te_ary, columns=te.columns_)
            df.head()
                        aluminum
                                                                                                dishwash
                   all-
                                                                                     dinner
Out [ 108...
                                           beef butter cereals cheeses coffee/tea
                                   bagels
              purpose
                              foil
                                                                                       rolls
                                                                                             liquid/deterg
           0
                  True
                                           True
                                                          False
                                                                    False
                                                                                       True
                                                                                                       Fa
                             True
                                    False
                                                   True
                                                                               False
           1
                 False
                             True
                                          False
                                                  False
                                                           True
                                                                     True
                                                                               False
                                                                                       False
                                                                                                       Τ
                                    False
```

False

False

True

True

True

False

False

False

True

False

Fa

Fa

Стр. 1 из 10 19.11.2020, 19:34

	all- purpose	aluminum foil	bagels	beef	butter	cereals	cheeses	coffee/tea	dinner rolls	dishwash liquid/deterg
4	True	False	False	False	False	False	False	False	True	Fa

Данные теперь представляются в виде матрицы: строки - транзакции, столбцы - наличие в транзакции элемента, ячейка - есть/нет в транзации

## PART 3 APRIORI

После подготовки данных можно воспользоваться алгоритмом Априори

Запуск Априори с минимальным уровнем поддержки 0.3

```
In [109... results = apriori(df, min_support=0.3, use_colnames=True)
    results['length'] = results['itemsets'].apply(lambda x: len(x))
    results
```

Out[109		support	itemsets	length
	0	0.374890	(all- purpose)	1
	1	0.384548	(aluminum foil)	1
	2	0.385426	(bagels)	1
	3	0.374890	(beef)	1
	4	0.367867	(butter)	1
	5	0.395961	(cereals)	1
	6	0.390694	(cheeses)	1
	7	0.379280	(coffee/tea)	1
	8	0.388938	(dinner rolls)	1
	9	0.388060	(dishwashing liquid/detergent)	1
	10	0.389816	(eggs)	1
	11	0.352941	(flour)	1
	12	0.370500	(fruits)	1
	13	0.345917	(hand soap)	1
	14	0.398595	(ice cream)	1
	15	0.375768	(individual meals)	1
	16	0.376646	(juice)	1
	17	0.371378	(ketchup)	1
	18	0.378402	(laundry detergent)	1
	19	0.395083	(lunch meat)	1
	20	0.380158	(milk)	1
	21	0.375768	(mixes)	1
	22	0.362599	(paper towels)	1
	23	0.371378	(pasta)	1
	24	0.355575	(pork)	1

Стр. 2 из 10 19.11.2020, 19:34

	support	itemsets	length
25	0.421422	(poultry)	1
26	0.367867	(sandwich bags)	1
27	0.349429	(sandwich loaves)	1
28	0.368745	(shampoo)	1
29	0.379280	(soap)	1
30	0.390694	(soda)	1
31	0.373134	(spaghetti sauce)	1
32	0.360843	(sugar)	1
33	0.378402	(toilet paper)	1
34	0.369622	(tortillas)	1
35	0.739245	(vegetables)	1
36	0.394205	(waffles)	1
37	0.384548	(yogurt)	1
38	0.310799	(aluminum foil, vegetables)	2
39	0.300263	(vegetables, bagels)	2
40	0.310799	(vegetables, cereals)	2
41	0.309043	(cheeses, vegetables)	2
42	0.308165	(dinner rolls, vegetables)	2
43	0.306409	(dishwashing liquid/detergent, vegetables)	2
44	0.326602	(vegetables, eggs)	2
45	0.302897	(ice cream, vegetables)	2
46	0.309043	(laundry detergent, vegetables)	2
47	0.311677	(lunch meat, vegetables)	2
48	0.331870	(poultry, vegetables)	2
49	0.305531	(vegetables, soda)	2
50	0 315189	(waffles vegetables)	2

Была получена таблица, в которой перечисленны все повторяющиеся элементы с вероятностью больше 0.3. В последнем столбце показана длина повторяющегося набора.

Применим Априори, но с ограничением на размер набора, равным 1

In [110... results = apriori(df, min\_support=0.3, use\_colnames=True, max\_len=1)
 results

Out[110		support	itemsets
	0	0.374890	(all- purpose)
	1	0.384548	(aluminum foil)
	2	0.385426	(bagels)
	3	0.374890	(beef)

Стр. 3 из 10 19.11.2020, 19:34

<ul> <li>4 0.367867</li> <li>5 0.395961</li> <li>6 0.390694</li> <li>7 0.379280</li> <li>8 0.388938</li> </ul>	(butter) (cereals) (cheeses) (coffee/tea) (dinner rolls) shing liquid/detergent) (eggs) (flour)
<ul><li>6 0.390694</li><li>7 0.379280</li></ul>	(cheeses (coffee/tea (dinner rolls shing liquid/detergent (eggs
<b>7</b> 0.379280	(coffee/tea (dinner rolls shing liquid/detergent (eggs
	(dinner rolls shing liquid/detergent (eggs
<b>8</b> 0.388938	shing liquid/detergent (eggs
	(eggs
<b>9</b> 0.388060 (dishwa	
<b>10</b> 0.389816	(flour
<b>11</b> 0.352941	
<b>12</b> 0.370500	(fruits
<b>13</b> 0.345917	(hand soap
<b>14</b> 0.398595	(ice cream
<b>15</b> 0.375768	(individual meals
<b>16</b> 0.376646	(juice
<b>17</b> 0.371378	(ketchup
<b>18</b> 0.378402	(laundry detergent
<b>19</b> 0.395083	(lunch meat
<b>20</b> 0.380158	(milk
<b>21</b> 0.375768	(mixes
<b>22</b> 0.362599	(paper towels
<b>23</b> 0.371378	(pasta
<b>24</b> 0.355575	(pork
<b>25</b> 0.421422	(poultry
<b>26</b> 0.367867	(sandwich bags
<b>27</b> 0.349429	(sandwich loaves
<b>28</b> 0.368745	(shampoo
<b>29</b> 0.379280	(soap
<b>30</b> 0.390694	(soda
<b>31</b> 0.373134	(spaghetti sauce
<b>32</b> 0.360843	(sugar
<b>33</b> 0.378402	(toilet paper
<b>34</b> 0.369622	(tortillas
<b>35</b> 0.739245	(vegetables
<b>36</b> 0.394205	(waffles
Применим Априори і	и выведем только

support

itemsets

Применим Априори и выведем только наборы с размером 2, а также количество таких наборов

Стр. 4 из 10 19.11.2020, 19:34

```
results = apriori(df, min_support=0.3, use_colnames=True)
results['length'] = results['itemsets'].apply(lambda x: len(x))
results = results[results['length'] == 2]
print(results)
print('\nCount of result itemstes = ',len(results))
```

```
support
                                               itemsets length
                            (aluminum foil, vegetables)
38 0.310799
                                   (vegetables, bagels)
39 0.300263
                                                              2
40 0.310799
                                   (vegetables, cereals)
                                                              2
41 0.309043
                                                              2
                                   (cheeses, vegetables)
                                                              2
42 0.308165
                              (dinner rolls, vegetables)
43 0.306409
             (dishwashing liquid/detergent, vegetables)
                                                              2
                                                              2
44 0.326602
                                      (vegetables, eggs)
                                                              2
45 0.302897
                                 (ice cream, vegetables)
                                                              2
46 0.309043
                        (laundry detergent, vegetables)
47 0.311677
                               (lunch meat, vegetables)
                                                              2
48 0.331870
                                   (poultry, vegetables)
                                                              2
49 0.305531
                                      (vegetables, soda)
                                                              2
                                                              2
50 0.315189
                                   (waffles, vegetables)
                                                              2
51 0.319579
                                   (yogurt, vegetables)
```

Count of result itemstes = 14

Посчитаем количество наборов при различных уровнях поддержки. Начальное значение поддержки 0.05, шаг 0.01. Определите значение уровня поддержки при котором перестают генерироваться наборы размера 1,2,3, и.т.д.

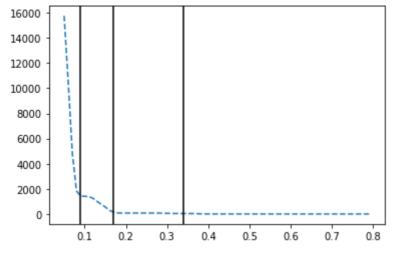
```
In [112...
          min support = 0.05
          max\_support = 0.8
          step support = 0.01
          support len = dict()
          support_len_not_in_N = dict()
          prev = 1000
          for support in np.arange(min_support, max_support, step_support):
              results = apriori(df, min support=support, use colnames=True)
              support len[support] = len(results)
              if len(results) == 0:
                  continue
              results['length'] = results['itemsets'].apply(lambda x: len(x))
              cur max = np.max(results['length'])
              if cur max < prev:</pre>
                  support_len_not_in_N[support] = prev
                  prev = cur max
          support_len_not_in_N.pop(min_support)
```

Out[112... 1000

Постройте график зависимости количества наборов от уровня поддержки Отметьте полученные уровни поддержки на графике

Стр. 5 из 10 19.11.2020, 19:34

```
In [113... plt.plot(support_len.keys(), support_len.values(), '--')
for key in support_len_not_in_N.keys():
    plt.axvline(key, color='k')
```



Построим датасет только из тех элементов, которые попадают в наборы размером 1 при уровне поддержки 0.38

Приведем полученный датасет к формату, который можно обработать

```
In [115... te = TransactionEncoder()
    te_ary = te.fit_transform(new_dataset)
    df = pd.DataFrame(te_ary, columns=te.columns_)
    df.head()
```

Out[115		aluminum foil	bagels	cereals	cheeses	dinner rolls	dishwashing liquid/detergent	eggs	ice cream	lunch meat	milk	pc
	0	True	False	False	False	True	False	False	True	True	False	
	1	True	False	True	True	False	True	False	False	False	True	
	2	False	True	True	True	True	False	True	True	True	True	
	3	False	False	True	False	False	False	False	False	True	False	
	4	False	False	False	False	True	False	True	False	False	True	

Проведем ассоциативный анализ при уровне поддержки 0.3 для нового датасета. Опишите в чем сходства и различия

```
In [116... results = apriori(df, min_support=0.3, use_colnames=True)
    results
```

Out[116	support	itemsets
	<b>0</b> 0.384548	(aluminum foil)
	<b>1</b> 0.385426	(bagels)
	<b>2</b> 0.395961	(cereals)
	<b>3</b> 0.390694	(cheeses)

Стр. 6 из 10 19.11.2020, 19:34

	support	itemsets
4	0.388938	(dinner rolls)
5	0.388060	(dishwashing liquid/detergent)
6	0.389816	(eggs)
7	0.398595	(ice cream)
8	0.395083	(lunch meat)
9	0.380158	(milk)
10	0.421422	(poultry)
11	0.390694	(soda)
12	0.739245	(vegetables)
13	0.394205	(waffles)
14	0.384548	(yogurt)
15	0.310799	(aluminum foil, vegetables)
16	0.300263	(vegetables, bagels)
17	0.310799	(vegetables, cereals)
18	0.309043	(cheeses, vegetables)
19	0.308165	(dinner rolls, vegetables)
20	0.306409	(dishwashing liquid/detergent, vegetables)
21	0.326602	(vegetables, eggs)
22	0.302897	(ice cream, vegetables)
23	0.311677	(lunch meat, vegetables)
24	0.331870	(poultry, vegetables)
25	0.305531	(vegetables, soda)
26	0.315189	(waffles, vegetables)

Проведем ассоциативный анализ при уровне поддержки 0.15 для нового датасета. Выведем все наборы размер которых больше 1 и в котором есть 'yogurt' или 'waffles'

In [117... results = apriori(df, min\_support=0.15, use\_colnames=True)

results[['vogurt' in results["itemsets"][i] or 'vaffles' in results["itemsets"][i]

	res	sults[['yogurt' :	<pre>in results["itemsets"</pre>	'][i] <b>o</b> r	'waffles'	in	results["items
Out[117		support	itemsets				
	13	0.394205	(waffles)				
	14	0.384548	(yogurt)				
	27	0.169447	(aluminum foil, waffles)				
	28	0.177349	(aluminum foil, yogurt)				
	40	0.159789	(waffles, bagels)				
	41	0.162423	(yogurt, bagels)				
	52	0.160667	(waffles, cereals)				
	53	0.172081	(yogurt, cereals)				
	63	0.172959	(waffles, cheeses)				

Стр. 7 из 10 19.11.2020, 19:34

itemsets	support	
(cheeses, yogurt)	0.172081	64
(dinner rolls, waffles)	0.169447	73
(dinner rolls, yogurt)	0.166813	74
(waffles, dishwashing liquid/detergent)	0.175593	82
(dishwashing liquid/detergent, yogurt)	0.158033	83
(waffles, eggs)	0.169447	90
(yogurt, eggs)	0.174715	91
(ice cream, waffles)	0.172959	97
(ice cream, yogurt)	0.156277	98
(waffles, lunch meat)	0.184372	103
(lunch meat, yogurt)	0.161545	104
(yogurt, milk)	0.167691	108
(poultry, waffles)	0.166813	111
(poultry, yogurt)	0.180860	112
(waffles, soda)	0.177349	114
(yogurt, soda)	0.167691	115
(waffles, vegetables)	0.315189	116
(yogurt, vegetables)	0.319579	117
(waffles, yogurt)	0.173837	118
(aluminum foil, yogurt, vegetables)	0.152766	119
(yogurt, vegetables, eggs)	0.157155	128
(waffles, lunch meat, vegetables)	0.157155	130

Построим датасет, из тех элементов, которые не попали в датасет в п. 6 и приведем его к удобному для анализа виду

```
all-
                                                                  hand
                                                                        individual
Out[119...
                          beef butter coffee/tea
                                                    flour fruits
                                                                                    juice ketchup ... pasta
               purpose
                                                                  soap
                                                                            meals
            0
                   True
                          True
                                  True
                                             False
                                                    True
                                                           False
                                                                  False
                                                                              False
                                                                                    False
                                                                                              False
                                                                                                         False
            1
                  False
                         False
                                 False
                                             False
                                                    False
                                                           False
                                                                              True
                                                                                    False
                                                                                              False
                                                                                                         False
                                                                   True
            2
                  False False
                                 False
                                             False
                                                   False
                                                                             False
                                                                                    False
                                                                                               True
                                                                                                         False
                                                           False
                                                                   True
                   True False
            3
                                 False
                                             False False False
                                                                             False
                                                                                     True
                                                                                              False
                                                                                                         False
```

Стр. 8 из 10 19.11.2020, 19:34

```
all-
purpose beef butter coffee/tea flour fruits hand individual
soap meals juice ketchup ... pasta
```

Проведем анализ Apriori для полученного датасета

```
In [120... results = apriori(df, min_support=0.1, use_colnames=True)
    results
```

```
support
                                                  itemsets
Out [120...
                0 0.374890
                                              (all-purpose)
                1 0.374890
                                                     (beef)
               2 0.367867
                                                    (butter)
                3 0.379280
                                                (coffee/tea)
                   0.352941
                                                     (flour)
                  0.151888 (spaghetti sauce, toilet paper)
             271
             272 0.148376
                                  (spaghetti sauce, tortillas)
             273 0.151888
                                        (toilet paper, sugar)
             274 0.147498
                                            (sugar, tortillas)
             275 0.156277
                                       (toilet paper, tortillas)
```

276 rows × 2 columns

Напишем правило, для вывода всех наборов, в которых хотя бы два элемента начинаются на 's'

```
In [122... a = results["support"] < 0.25
b = results["support"] > 0.1
results[a & b]
```

Out [122... support itemsets

изменяется от 0.1 до 0.25

Стр. 9 из 10 19.11.2020, 19:34

itemsets		support	
all- purpose)	(beef,	0.144864	23
pose, butter)	(all- pur	0.147498	24
all- purpose)	(coffee/tea,	0.146620	25
urpose, flour)	(all- pu	0.142230	26
all- purpose)	(fruits,	0.150132	27
toilet paper)	(spaghetti sauce,	0.151888	271
uce, tortillas)	(spaghetti sa	0.148376	272
paper, sugar)	(toilet p	0.151888	273
ıgar, tortillas)	(su	0.147498	274
aper, tortillas)	(toilet pa	0.156277	275

Стр. 10 из 10 19.11.2020, 19:34